

BỘ TÀI NGUYÊN VÀ MÔI TRƯỜNG
TRƯỜNG ĐẠI HỌC TÀI NGUYÊN VÀ MÔI TRƯỜNG TP.HCM



NGÀNH CÔNG NGHỆ THÔNG TIN

MÔN HỌC: NHẬP MÔN TRÍ TUỆ NHÂN TẠO

Credit Risk Estimation

Học viên:

1250080168 - Nguyễn Trần Minh Tân

1250080238 - Nguyễn Văn Vũ

1250080200 - Châu Bảo Toàn

Giảng viên:

Nguyễn Duy Tuấn

Nguyễn Phan Chí Thành

Ước lượng Rủi ro Tín dụng Germany

Phân tích Khám phá Dữ liệu, Phân cụm K-Means và các Mô hình Học máy

Nhóm 9

April 26, 2026

Contents

1	Giới thiệu	3
2	Bộ dữ liệu và Phân tích Khám phá Dữ liệu (EDA)	3
2.1	Tổng quan bộ dữ liệu	3
2.2	Thống kê mô tả	3
2.3	Phân phối biến mục tiêu	4
2.4	Phân phối các biến số	4
3	Tiền xử lý Dữ liệu	5
3.1	Xử lý Giá trị Thiếu	5
3.2	Chiến lược Mã hóa (Encoding)	5
3.3	Chuẩn hóa và Tách dữ liệu	6
4	Phân cụm K-Means (Risk Bucketing)	6
4.1	Nền tảng Lý thuyết	6
4.2	Lựa chọn Số cụm Tối ưu	6
4.2.1	Phương pháp Khuỷu tay (Elbow Method)	6
4.2.2	Điểm Silhouette	7
4.2.3	Tiêu chí Calinski-Harabasz (CH)	8
4.2.4	Phân tích Gap (Gap Analysis)	9
4.3	Tổng hợp và Kết quả Phân cụm	10
4.3.1	Đặc điểm từng Cụm	10
5	Xử lý Mất cân bằng Lớp: SMOTEENN	11
5.1	Vấn đề Mất cân bằng Lớp	11
5.2	Phương pháp SMOTEENN	11
6	Các Mô hình Học máy	11
6.1	Hồi quy Logistic (Logistic Regression)	11
6.2	Support Vector Machine (SVM)	12
6.3	Random Forest	13
6.4	Multilayer Perceptron (MLP)	13
6.5	Deep Learning (TensorFlow/Keras)	14
7	Kết quả và So sánh	15
7.1	Tóm tắt ROC-AUC	15
7.2	Đường cong ROC	15
7.3	Phân tích Kết quả	16
7.4	Nhận xét về Phương pháp SMOTEENN	17

8	Kết luận	17
8.1	Hiệu suất Mô hình	17
8.2	Nhận xét và Hướng phát triển	17
8.3	Kết luận Cuối cùng	18
A	Phụ lục: Cấu hình Hyperparameter Tốt nhất	18

1 Giới thiệu

Rủi ro tín dụng là rủi ro phát sinh khi người vay không thể thực hiện nghĩa vụ nợ của mình [?]. Đây là một trong những loại rủi ro quan trọng nhất mà các tổ chức tài chính phải đối mặt. Mục tiêu chính của báo cáo này là ước lượng xác suất vỡ nợ (Probability of Default – PD) bằng các kỹ thuật học máy áp dụng trên bộ dữ liệu German Credit.

Rủi ro tín dụng được xác định bởi ba thành phần chính:

- **Phơi nhiễm (Exposure):** Bên có thể không thực hiện được nghĩa vụ hoặc có sự thay đổi bất lợi về khả năng thanh toán.
- **Khả năng vỡ nợ (Likelihood):** Xác suất bên đó không đáp ứng được nghĩa vụ của mình.
- **Tỷ lệ thu hồi (Recovery rate):** Lượng tài sản có thể thu hồi nếu vỡ nợ xảy ra.

Ủy ban Basel (BCBS) đề xuất các tiêu chuẩn quản lý rủi ro tín dụng toàn cầu thông qua Hiệp ước Basel. Phương pháp tiếp cận dựa trên xếp hạng nội bộ (IRB) sử dụng công thức:

$$\text{Expected Loss} = \text{EAD} \times \text{LGD} \times \text{PD} \quad (1)$$

trong đó PD là xác suất vỡ nợ, LGD là tổn thất khi vỡ nợ ($0 \leq \text{LGD} \leq 1$), và EAD là giá trị phơi nhiễm tại thời điểm vỡ nợ.

Báo cáo trình bày pipeline đầy đủ: EDA $\rightarrow$ Tiền xử lý $\rightarrow$ Phân cụm K-Means $\rightarrow$ Xử lý mất cân bằng lớp (SMOTEENN) $\rightarrow$ Huấn luyện và đánh giá các mô hình học máy.

2 Bộ dữ liệu và Phân tích Khám phá Dữ liệu (EDA)

2.1 Tổng quan bộ dữ liệu

Bộ dữ liệu German Credit được thu thập từ nền tảng Kaggle, bao gồm **1.000 quan sát** và **9 đặc trưng** (features). Biến mục tiêu là *Risk* với hai giá trị: *good* (tốt) và *bad* (xấu).

Table 1: Mô tả các đặc trưng trong bộ dữ liệu

Đặc trưng	Kiểu	Mô tả
Age	Số (Numerical)	Tuổi của người vay
Sex	Phân loại	Giới tính (male/female)
Job	Thứ bậc	Loại công việc (0–không kỹ năng, 3–kỹ năng cao)
Housing	Phân loại	Chỗ ở (own/free/rent)
Saving accounts	Phân loại	Tài khoản tiết kiệm (little/moderate/quite rich/rich)
Checking account	Phân loại	Tài khoản thanh toán (little/moderate/rich)
Credit amount	Số	Số tiền vay (DM)
Duration	Số	Thời hạn vay (tháng)
Purpose	Phân loại	Mục đích vay (car/furniture/education/...)

2.2 Thống kê mô tả

Thống kê mô tả cho các biến số được trình bày trong Bảng 2. Tuổi trung bình của khách hàng là 35,5 tuổi. Số tiền vay trung bình là 3.271 DM với độ lệch chuẩn rất cao (2.822 DM), phản ánh sự phân tán lớn trong khoản vay. Thời hạn vay trung bình là 20,9 tháng.

Table 2: Thống kê mô tả các biến số

Chỉ số	Age	Job	Credit amount	Duration
Count	1000	1000	1000	1000
Mean	35.546	1.904	3271.258	20.903
Std	11.375	0.654	2822.737	12.059
Min	19.000	0.000	250.000	4.000
25%	27.000	2.000	1365.500	12.000
50%	33.000	2.000	2319.500	18.000
75%	42.000	2.000	3972.250	24.000
Max	75.000	3.000	18424.000	72.000

2.3 Phân phối biến mục tiêu

Biến mục tiêu Risk có phân phối không cân bằng: **700 quan sát Good (70%)** và **300 quan sát Bad (30%)**. Sự mất cân bằng lớp này cần được xử lý trước khi huấn luyện mô hình để tránh mô hình bị thiên lệch về phía lớp đa số.




Figure 1: Phân phối biến mục tiêu Risk: 700 Good (70%) và 300 Bad (30%)

2.4 Phân phối các biến số

Các biến số (Age, Credit amount, Duration) đều có phân phối lệch phải (positively skewed). Riêng biến Job là biến rời rạc nên có độ phân tán thấp, tập trung chủ yếu ở giá trị 2 (skilled).

Phân phối các biến số




Figure 2: Histogram của các biến số trong bộ dữ liệu

3 Tiền xử lý Dữ liệu

3.1 Xử lý Giá trị Thiếu

Bộ dữ liệu có hai cột bị thiếu giá trị:

- **Saving accounts:** 183 giá trị thiếu (18,3%) – điền bằng *mode = little*
- **Checking account:** 394 giá trị thiếu (39,4%) – điền bằng *mode = little*

Chiến lược điền mode cho biến phân loại giúp giữ nguyên phân phối tần suất của từng nhóm mà không làm sai lệch ý nghĩa thống kê.

3.2 Chiến lược Mã hóa (Encoding)

Do các mô hình học máy khác nhau có yêu cầu khác nhau về biểu diễn dữ liệu, chúng tôi áp dụng chiến lược mã hóa theo từng nhóm mô hình:

Table 3: Chiến lược mã hóa theo nhóm mô hình

Nhóm mô hình	Phương pháp	Lý do
Dựa trên khoảng cách: K-Means, KNN	One-Hot (không bỏ cột)	Khoảng cách Euclidean yêu cầu vector đơn vị bằng nhau cho mỗi danh mục
Dựa trên cây: Decision Tree, Random Forest	Ordinal Encoder	Cây dùng ngưỡng phân chia; thứ tự thứ bậc là đủ
Tuyến tính: Logistic Regression, SVM, MLP	One-Hot (bỏ cột đầu)	Tránh đa cộng tuyến hoàn hảo trong $\mathbf{w}^T \mathbf{x}$

Trong pipeline thực tế, chúng tôi sử dụng **One-Hot Encoding (drop='first')** cho biến Purpose (9 cột) và **Ordinal Encoding** cho 3 biến thứ tự là Housing, Checking Account và Saving Account (3 cột). Kết hợp với 4 biến số, ma trận đặc trưng cuối cùng có kích thước **1000×16**.

3.3 Chuẩn hóa và Tách dữ liệu

Quy trình chuẩn bị dữ liệu theo thứ tự:

1. **Tách Train/Test** theo tỷ lệ 80/20 (stratified) trước khi chuẩn hóa để tránh data leakage: Train = 800, Test = 200.
2. **StandardScaler** được fit trên tập Train và áp dụng cho cả Train lẫn Test (chỉ chuẩn hóa 4 biến số; các biến one-hot giữ nguyên giá trị 0/1).
3. Phân phối nhãn sau khi tách: Train {Good: 560, Bad: 240}; Test {Good: 140, Bad: 60}.

4 Phân cụm K-Means (Risk Bucketing)

4.1 Nền tảng Lý thuyết

Risk bucketing (phân nhóm rủi ro) là kỹ thuật gom nhóm những người vay có mức độ tín dụng tương đồng. Mục tiêu là tạo ra các nhóm đồng nhất để mô hình học máy có thể ước lượng xác suất vỡ nợ chính xác hơn cho từng phân khúc.

K-Means tối thiểu hóa tổng bình phương khoảng cách nội cụm:

$$\min \sum_{i=1}^K \sum_{x \in C_i} \|x - C_i\|^2 \quad (2)$$

trong đó x là một quan sát và C_i là tâm cụm (centroid) thứ i .

Thuật toán sử dụng quy trình Kỳ vọng – Tối đa hóa (E-M):

1. Chọn k điểm ngẫu nhiên làm centroid ban đầu.
2. Gán mỗi quan sát vào centroid gần nhất.
3. Cập nhật centroid bằng giá trị trung bình của các quan sát trong cụm.
4. Lặp lại bước 2–3 cho đến khi hội tụ.

4.2 Lựa chọn Số cụm Tối ưu

Chúng tôi áp dụng bốn phương pháp để xác định số cụm k tối ưu:

4.2.1 Phương pháp Khuỷu tay (Elbow Method)

Inertia (tổng bình phương khoảng cách đến centroid) giảm dần khi k tăng. Điểm khuỷu tay – nơi đường cong bắt đầu phẳng hơn – cho thấy sự đánh đổi tối ưu giữa số cụm và mức độ nén dữ liệu. Kết quả đề xuất $k = 2$.




Figure 3: Phương pháp Khuỷu tay xác định số cụm K-Means (đề xuất $k = 2$)

4.2.2 Điểm Silhouette

Silhouette score đo lường mức độ phù hợp của mỗi quan sát với cụm của nó so với các cụm lân cận, được tính theo công thức:

$$s = \frac{b - a}{\max(a, b)} \quad (3)$$

trong đó a là khoảng cách nội cụm trung bình và b là khoảng cách liên cụm trung bình nhỏ nhất. Giá trị gần 1 là tốt nhất. Kết quả đề xuất $k = 2$.




Figure 4: Phương pháp Silhouette Score xác định số cụm K-Means (đề xuất $k = 2$)

4.2.3 Tiêu chí Calinski-Harabasz (CH)

Điểm CH (còn gọi là variance ratio criterion) đánh giá tỷ số phân tán liên cụm trên phân tán nội cụm:

$$CH = \frac{SSB}{SSW} \cdot \frac{N - k}{k - 1} \quad (4)$$

trong đó SSB là phương sai liên cụm, SSW là phương sai nội cụm, N là số quan sát và k là số cụm. Điểm CH cao hơn là tốt hơn. Kết quả đề xuất $k = 2$.




Figure 5: Phương pháp CH Score xác định số cụm K-Means (đề xuất $k = 2$)

4.2.4 Phân tích Gap (Gap Analysis)

Gap statistic so sánh tổng phương sai nội cụm thực tế với kỳ vọng dưới phân phối tham chiếu ngẫu nhiên. Số cụm tối ưu là giá trị k tối đa hóa gap value.




Figure 6: Phân tích Gap xác định số cụm tối ưu (đề xuất $k = 5$)

4.3 Tổng hợp và Kết quả Phân cụm

Kết quả từ bốn phương pháp được tóm tắt trong Bảng 4:

Table 4: Tổng hợp đề xuất số cụm từ 4 phương pháp

Phương pháp	k đề xuất	Ghi chú
Elbow (Inertia)	2	Điểm khuỷu tay
Silhouette Score	2	Điểm cao nhất
Calinski-Harabasz	2	Điểm CH cao nhất
Gap Statistic	5	Gap value lớn nhất
Quyết định cuối	2	Đa số bỏ phiếu

Dựa trên nguyên tắc đa số bỏ phiếu, chúng tôi chọn $k = 2$ làm số cụm tối ưu.

4.3.1 Đặc điểm từng Cụm

Sau khi áp dụng K-Means với $k = 2$ trên tập train (800 mẫu):

Table 5: Phân tích đặc điểm hai cụm

Cụm	Số mẫu	Tỷ lệ	Bad rate (tỷ lệ good=1)
Cụm 0	630	78,75%	0,735
Cụm 1	170	21,25%	0,571

Cụm 0 chứa đa số khách hàng với bad rate cao hơn (73,5%), trong khi Cụm 1 có tỷ lệ cân bằng hơn giữa Good và Bad (57,1%). Điều này phản ánh hai phân khúc khách hàng có mức độ rủi ro tín dụng khác biệt rõ rệt.

5 Xử lý Mất cân bằng Lớp: SMOTEENN

5.1 Vấn đề Mất cân bằng Lớp

Trong tập train gốc: **560 Good (70%)** và **240 Bad (30%)**. Sự mất cân bằng này khiến mô hình có xu hướng dự đoán thiên về lớp đa số (Good), dẫn đến bỏ sót nhiều trường hợp vỡ nợ thực sự – điều đặc biệt nguy hiểm trong bài toán tín dụng.

5.2 Phương pháp SMOTEENN

Chúng tôi sử dụng kết hợp SMOTE (Synthetic Minority Oversampling Technique) và ENN (Edited Nearest Neighbor):

- **SMOTE**: Tạo ra các mẫu tổng hợp cho lớp thiểu số (Bad) bằng cách nội suy giữa các quan sát lân cận, giúp tăng số lượng mẫu xấu trong tập huấn luyện.
- **ENN**: Loại bỏ các quan sát bị phân loại sai bởi k hàng xóm gần nhất, làm sạch biên phân loại và giảm nhiễu giữa hai lớp.

Kết quả sau SMOTEENN: Tập train từ 800 mẫu giảm xuống còn **602 mẫu** với phân phối {Bad: 380, Good: 222} – gần như đảo chiều tỷ lệ, giúp mô hình chú ý nhiều hơn đến lớp thiểu số Bad.

6 Các Mô hình Học máy

Toàn bộ các mô hình được huấn luyện trên tập `X_train_final` (602 mẫu sau SMOTEENN) và đánh giá trên tập test gốc (200 mẫu, không áp dụng SMOTEENN). Hyperparameter tuning sử dụng `HalvingRandomSearchCV` để tối ưu hiệu suất với tài nguyên tính toán hợp lý.

6.1 Hồi quy Logistic (Logistic Regression)

Hồi quy Logistic là mô hình phân loại nền tảng, mô hình hóa xác suất có điều kiện thông qua hàm sigmoid:

$$P(\text{bad} \mid \mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}} \quad (5)$$

Thiết lập: `class_weight='balanced', max_iter=1000`.

10 đặc trưng có hệ số tuyệt đối lớn nhất (ảnh hưởng nhất đến dự đoán):

Table 6: Top 10 hệ số Logistic Regression

Đặc trưng	Hệ số
Checking account_nan	+3.1646
Purpose_radio/TV	+2.2253
Saving accounts_nan	+1.3626
Saving accounts_moderate	+1.3327
Saving accounts_rich	+1.1404
Duration	-1.0166
Saving accounts_quite rich	+0.9384
Checking account_rich	+0.8597
Housing_own	+0.7640
Age	+0.6563

Kết quả: ROC-AUC = 0,5437




Figure 7: Mô hình AUC-ROC Logistic Regression trên từng cluster

6.2 Support Vector Machine (SVM)

SVM tìm siêu phẳng tối ưu phân tách hai lớp với biên quyết định rộng nhất. Sử dụng kernel Gaussian (RBF) để xử lý dữ liệu phi tuyến:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2) \quad (6)$$

Tham số tối ưu (HalvingRandomSearchCV): **kernel=rbf**, **gamma=0.1**, **C=10**.

Giá trị $C = 10$ lớn cho thấy mô hình ưu tiên phân loại chính xác hơn là biên rộng. $\gamma = 0.1$ cho bán kính ảnh hưởng vừa phải của mỗi điểm hỗ trợ (support vector).

Kết quả: ROC-AUC = 0,5181




Figure 8: Mô hình AUC-ROC Support Vector Machine (SVM) trên từng cluster

6.3 Random Forest

Random Forest là mô hình tổ hợp (ensemble) phi tham số, kết hợp nhiều cây quyết định huấn luyện trên các tập con ngẫu nhiên của dữ liệu và đặc trưng. Dự đoán cuối cùng dựa trên bỏ phiếu đa số (classification) từ tất cả các cây.

Tham số tối ưu: `n_estimators=300, min_samples_split=10, max_features=log2, max_depth=None, criterion=gini`.

Kết quả: ROC-AUC = 0,6059




Figure 9: Mô hình AUC-ROC Random Forest trên từng cluster

6.4 Multilayer Perceptron (MLP)

Multilayer Perceptron (MLP) là mạng nơ-ron phân lớp với các lớp ẩn:

Tham số tối ưu: `hidden_layer_sizes=(50, 50), solver=adam, learning_rate_init=0.01, activation=relu`.

Kiến trúc hai lớp ẩn (50–50 neurons) với hàm kích hoạt ReLU và trình tối ưu Adam cho phép mô hình học được các quan hệ phi tuyến phức tạp trong dữ liệu tín dụng.

Kết quả: ROC-AUC = 0,5470




Figure 10: Mô hình AUC-ROC Multilayer Perceptron trên từng cluster

6.5 Deep Learning (TensorFlow/Keras)

Mô hình Deep Learning sử dụng kiến trúc deeper với các lớp Dense và Dropout:

- Lớp đầu vào: 21 đặc trưng
- Lớp ẩn 1: 128 neurons (ReLU)
- Lớp ẩn 2: 64 neurons (ReLU)
- Lớp ẩn 3: 8 neurons (ReLU)
- Dropout: tỷ lệ 0,2
- Lớp đầu ra: 1 neuron (Sigmoid)

Sử dụng **EarlyStopping** (patience=8) để tránh overfitting. Hàm mất mát là binary cross-entropy, trình tối ưu là Adam.

Kết quả: ROC-AUC = 0,4073




Figure 11: Mô hình AUC-ROC Deep Learning trên từng cluster

7 Kết quả và So sánh

7.1 Tóm tắt ROC-AUC

Table 7: So sánh hiệu suất các mô hình (ROC-AUC trên tập test)

Mô hình	ROC-AUC	Xếp hạng
Random Forest (300 cây, max_features=log2)	0,6059	1
MLP (50-50)	0,5470	2
Logistic Regression	0,5437	3
SVM (kernel=RBF, $C = 10$, $\gamma = 0.1$)	0,5181	4
Deep Learning (Keras, 128-64-8)	0,4073	5




Figure 12: Biểu đồ so sánh ROC-AUC của các mô hình

7.2 Đường cong ROC

Đường cong ROC (Receiver Operating Characteristic) biểu diễn tỷ lệ True Positive Rate (TPR) theo False Positive Rate (FPR) ở các ngưỡng phân loại khác nhau. Diện tích dưới đường cong (AUC) càng gần 1 thì mô hình càng tốt; $AUC = 0,5$ tương đương phân loại ngẫu nhiên.




Figure 13: Đường cong ROC của các mô hình trên tập test

7.3 Phân tích Kết quả

- **Random Forest đạt hiệu suất cao nhất** ($AUC = 0,6059$) nhờ khả năng xử lý tốt đặc trưng hỗn hợp (số + nhị phân) và kháng overfitting thông qua kỹ thuật bagging. Khác với các mô hình khác, Random Forest không yêu cầu chuẩn hóa dữ liệu và có thể nắm bắt được các tương tác phi tuyến phức tạp trong dữ liệu tín dụng.
- **MLP xếp thứ hai** ($AUC = 0,5470$). Mạng nơ-ron hai lớp ẩn có khả năng học phi tuyến tốt hơn mô hình tuyến tính, nhưng vẫn thấp hơn Random Forest do có thể chưa tối ưu hóa hyperparameter hoặc cần thêm dữ liệu.
- **Logistic Regression xếp thứ ba** ($AUC = 0,5437$). Là mô hình baseline mạnh với khả năng giải thích cao thông qua hệ số hồi quy, nhưng hiệu suất thấp phản ánh tính chất tuyến tính của mô hình không đủ bắt được các quan hệ phi tuyến trong dữ liệu tín dụng.
- **SVM xếp thứ tư** ($AUC = 0,5181$). Mặc dù sử dụng kernel RBF có khả năng xử lý phi tuyến, nhưng hiệu suất thấp hơn Random Forest có thể do hyperparameter ($C = 10, \gamma = 0.1$) chưa tối ưu cho bộ dữ liệu này, hoặc kernel RBF quá phức tạp so với phân phối dữ liệu.
- **Deep Learning xếp cuối** ($AUC = 0,4073$). Mô hình phức tạp nhất nhưng lại kém hiệu quả nhất, dưới mức ngẫu nhiên ($AUC = 0,5$), phản ánh hiện tượng *overfitting* hoặc *underfitting* severe. EarlyStopping kích hoạt

ở epoch sớm cho thấy mô hình đã hội tụ quá sớm mà chưa học được các đặc trưng có ý nghĩa.

7.4 Nhận xét về Phương pháp SMOTEENN

SMOTEENN đã cân bằng lại tập huấn luyện từ {Good: 560, Bad: 240} thành {Bad: 380, Good: 222}, giúp các mô hình tập trung hơn vào việc nhận diện khách hàng có rủi ro cao. Tuy nhiên, kỹ thuật này cũng có thể tạo ra dữ liệu tổng hợp không phản ánh đúng thực tế phân phối.

8 Kết luận

Báo cáo này đã trình bày một pipeline đầy đủ để ước lượng rủi ro tín dụng trên bộ dữ liệu German Credit, bao gồm:

1. **EDA**: Phân tích phân phối biến, xác định mất cân bằng lớp (70% Good / 30% Bad) và các đặc điểm thống kê cơ bản.
2. **Tiền xử lý**: Xử lý missing values, One-Hot Encoding và chuẩn hóa StandardScaler (fit trên train, apply trên test). Ma trận đặc trưng cuối cùng có kích thước 1000×16 .
3. **K-Means Clustering**: Phân cụm risk bucketing với $k = 2$ dựa trên bộ phiếu đa số từ 4 phương pháp (Elbow, Silhouette, CH, Gap). Hai cụm phản ánh hai phân khúc khách hàng có mức rủi ro khác nhau (73,5% vs 57,1% bad rate).
4. **SMOTEENN**: Cân bằng lớp từ 800 mẫu (70% Good, 30% Bad) xuống 602 mẫu với phân phối gần như đảo chiều (37% Good, 63% Bad).
5. **Mô hình học máy**: So sánh 5 mô hình trên mỗi cụm, trong đó **Random Forest** đạt hiệu suất cao nhất ($AUC = 0,6059$), tiếp theo là **MLP** ($AUC = 0,5470$) và **Logistic Regression** ($AUC = 0,5437$).

8.1 Hiệu suất Mô hình

Các mô hình đạt hiệu suất AUC trong khoảng **0,41–0,61**, thấp hơn mức kỳ vọng (0,67–0,74). Nguyên nhân chính không phải do chất lượng mô hình mà từ **cách thiết kế pipeline**:

- **K-Means Clustering + SMOTEENN**: Dữ liệu được phân thành 2 cụm riêng biệt, huấn luyện mô hình *từng cụm* thay vì toàn bộ, làm giảm kích thước mẫu học tập. AUC báo cáo là trung bình giữa các cụm.
- **Phân phối dữ liệu không nhất quán**: Mỗi cụm có đặc điểm rủi ro khác nhau, khiến mô hình không tìm được ranh giới quyết định chung tối ưu.
- **Dữ liệu tổng hợp từ SMOTEENN**: Sự đảo chiều tỷ lệ lớp có thể làm mất tính chất thống kê gốc, tạo ra mẫu học tập không phản ánh phân phối thực tế.
- **Số lượng đặc trưng hạn chế**: Chỉ 16 đặc trưng từ 9 biến gốc có thể chưa đủ để bắt được toàn bộ thông tin rủi ro. Dữ liệu tín dụng thực tế thường cần đặc trưng hành vi (transaction history, payment patterns).

8.2 Nhận xét và Hướng phát triển

Thách thức hiện tại:

- Pipeline phức tạp (K-Means + SMOTEENN) tạo ra bài toán khó hơn so với huấn luyện trên toàn bộ dữ liệu cân bằng lớp.
- Bộ dữ liệu nhỏ (1.000 mẫu) hạn chế khả năng học của các mô hình phức tạp như Deep Learning.
- Dữ liệu thiếu các đặc trưng hành vi quan trọng.

Hướng cải thiện trong tương lai:

1. **Huấn luyện mô hình riêng biệt trên từng cụm** để tận dụng đặc tính risk bucketing, thay vì huấn luyện chung.

2. **Áp dụng XGBoost và LightGBM** – các mô hình boosting thường vượt trội trong dự báo tín dụng.
3. **Kỹ thuật Feature Engineering**: Tạo ra các đặc trưng tương tác (interaction features) hoặc áp dụng domain knowledge về tín dụng.
4. **Tối ưu ngưỡng phân loại** (classification threshold) theo tỷ lệ chi phí của false positive vs false negative trong thực tế ngân hàng.
5. **Mở rộng dữ liệu**: Tích hợp thêm đặc trưng hành vi (transaction data, payment history) để cải thiện hiệu suất dự báo.
6. **Giải thích mô hình** bằng SHAP values để nâng cao tính minh bạch trong quyết định tín dụng.

8.3 Kết luận Cuối cùng

Mặc dù AUC các mô hình hiện tại còn thấp, báo cáo này cung cấp một nền tảng vững chắc cho việc phát triển hệ thống ước lượng rủi ro tín dụng. Các cải thiện được đề xuất, đặc biệt là huấn luyện mô hình riêng biệt theo cụm và tích hợp thêm đặc trưng, dự kiến sẽ nâng cao đáng kể hiệu suất dự báo trong các giai đoạn tiếp theo.

A Phụ lục: Cấu hình Hyperparameter Tốt nhất

Table 8: Tham số tối ưu của các mô hình

Mô hình	Hyperparameter tối ưu
Logistic Regression	class_weight=balanced, max_iter=1000
SVM	kernel=rbf, $C = 10$, gamma=0.1, class_weight=balanced
Random Forest	n_estimators=300, max_features=log2, max_depth=None, criterion=gini, min_samples_split=10
MLP	hidden_layer_sizes=(50,50), solver=adam, learning_rate_init=0.01, activation=relu
Deep Learning	Dense(128→64→8→1), Dropout=0.2, optimizer=Adam, EarlyStopping(patience=8)